



大连海事大学
DALIAN MARITIME UNIVERSITY

本科毕业论文

题目： 基于强化学习的机器人控制方法研究
Research on Robot Control Methods Based on

Title: Reinforcement Learning

姓 名： 李济轩

学 号： 2220233878

学 院： 船舶电气工程学院

专业年级班级： 自动化 2023-4

指 导 教 师： 赵颖（教授）

完 成 日 期： 2026 年 3 月

基于强化学习的机器人控制方法研究

专业班级： 自动化 4 班

姓 名： 李济轩

指导教师： 赵颖

船舶电气工程学院

摘 要

传统机器人控制方法高度依赖精准动力学模型,面对非结构化复杂环境时自适应能力较弱、鲁棒性不足。针对该问题,本文聚焦基于强化学习的机器人智能控制方法展开研究,依托强化学习无模型自主决策、试错迭代优化的特性,构建机器人控制策略自主学习框架。文中梳理深度强化学习、策略梯度等主流算法在机器人运动规划、避障操控、精准作业中的应用,优化状态空间表征、奖励函数设计与策略更新机制,缓解训练效率低、虚实迁移难等瓶颈。通过对比分析,所提方法有效提升机器人环境适应能力与控制精度,为机器人智能化控制提供可行技术路径。

关键词: 强化学习; 机器人控制; 自适应控制; 智能机器人

Abstract

The traditional robot control methods highly rely on precise dynamic models. When facing unstructured and complex environments, they have weak adaptive capabilities and insufficient robustness. To address this issue, this paper focuses on the research of intelligent robot control methods based on reinforcement learning. Relying on the characteristics of reinforcement learning such as model-free autonomous decision-making and iterative optimization through trial and error, an autonomous learning framework for robot control strategies is constructed. The paper reviews the application logic of mainstream algorithms like deep reinforcement learning and policy gradient in robot motion planning, obstacle avoidance control, and precise operations, optimizes the representation of state space, the design of reward functions, and the strategy update mechanism, and alleviates bottlenecks such as low training efficiency and difficulty in transferring reality and virtuality. Through contrastive analysis the proposed method effectively improves the robot's adaptability to the environment and control accuracy, providing a feasible technical path for intelligent robot control.

Keywords: Reinforcement learning; Robot control; Adaptive control; Intelligent robot

目 录

摘要	1
第 1 章 绪论	1
1.1 引言	1
1.2 强化学习	1
1.3 研究背景	1
1.4 国内外研究现状	2
1.5 强化学习在机器人控制中的应用	3
1.5.1 机器人运动规划与轨迹优化	3
1.5.2 机械臂精准操作与柔性操控	4
1.5.4 机器人自主导航与姿态控制	5
参考文献	7

第 1 章 绪论

1.1 引言

机器学习是人工智能领域的核心分支，主要研究通过算法让计算机模拟人类学习行为，实现自主学习与智能决策，在自然语言处理、图像识别、自主控制等场景落地广泛。**强化学习**作为机器学习的重要分支，摒弃了监督学习依赖标注数据、无监督学习聚焦聚类分析的局限，以智能体与环境的试错交互为核心，自主习得最优决策策略，成为解决动态未知场景下自主决策问题的关键技术。机器人控制作为强化学习的典型应用载体，亟需突破传统控制瓶颈，实现智能化、柔性化升级。

现阶段机器人作业场景逐步从结构化固定环境，拓展至户外、家庭、动态车间等非结构化复杂环境，任务需求也向精准操作、实时避障、协同作业等高阶能力延伸。传统机器人控制方法高度依赖精准的动力学模型、人工预设轨迹与参数调试，面对环境扰动、任务变更时自适应能力差、鲁棒性不足，建模周期长、通用性弱，难以满足复杂场景下的自主控制需求。而强化学习无需预先构建精准数学模型，能够通过机器人本体与作业环境的持续交互，不断优化控制策略、适配环境变化，较为完美地契合机器人智能控制的技术诉求，成为破解上述难题的核心研究方向。

1.2 强化学习

强化学习是人工智能领域实现自主智能决策的核心技术，其基本思想来源于生物体“试错—反馈—修正”的学习机制^[1]。智能体（Agent）在与环境（Environment）的持续交互过程中，根据环境反馈不断调整自身策略，从而在未知场景中逐步学习到最优行为方式。不同于依赖大量标注样本建立输入输出映射关系的监督学习，也不同于侧重挖掘数据内在分布规律的无监督学习，强化学习以**长期累积回报最大化**为目标，本质上是一种典型的序贯决策学习方法^[3]。它无需显式先验知识和人工规则设计，能够通过自主探索完成策略迭代优化，因此被视为连接环境感知与运动控制、推动机器人实现自主化和智能化的关键技术路径。

从理论模型上看，强化学习通常可抽象为一个马尔可夫决策过程（Markov Decision Process, MDP），可表示为五元组：

$$\mathcal{M} \equiv \langle S, A, P, \mathcal{R}, \gamma \rangle \quad (1-1)$$

其中， S 表示状态空间， A 表示动作空间， $P(s' | s, a)$ 表示状态转移概率， $\mathcal{R}(s, a)$ 表示奖励函数， $\gamma \in [0, 1)$ 为折扣因子，用于权衡当前收益与未来收益。智能体在时刻 t 处于状态 s_t 时，根据策略 $\pi(a | s)$ 选择动作 a_t ，环境随后转移到下一状态 s_{t+1} ，并返回即时奖励 r_t 。强化学习的核心目标，是寻找一个最优策略 π^* ，使智能体在整个决策过程中获得的期望累积回报最大，即：

$$G_t \equiv \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \quad (1-2)$$

$$\pi^* \equiv \arg \max_{\pi} E_{\pi}[G_t] \quad (1-3)$$

在这一过程中，奖励函数是强化学习的关键设计要素，它将环境反馈量化为可优化的奖惩信号，引导智能体不断修正决策方向^[4]。智能体通过与环境形成“状态感知—动作选择—奖励反馈—策略更新”的闭环，不断削弱低收益行为、强化高收益行为，最终逼近最优决策路径。正是由于这种动态交互和在线优化机制，强化学习对于动态扰动、未知环境以及复杂任务场景具有较强的适应性和鲁棒性。

1.3 研究背景

随着智能制造、服务机器人、特种探测等领域的快速发展，机器人作业场景逐步从标准化、结构化的工业车间，拓展至野外、家庭、灾区、水下等非结构化复杂环境，作业任务也从单一重复的机械操作，向精准操控、动态适配、自主决策等高阶需求升级。传统机器人控制技术高度依赖精准的动力学建模、人工示教编程与预设控制参数，面对环境扰动、任务变更、未知障碍时，自适应能力弱、鲁棒性不足、通用性极差，不仅建模成本高昂、调试周期漫长，且难以应对动态复杂场景的自主作业需求，成为制约机器人智能化升级的核心瓶颈。在此背景下，探寻无需依赖先验模型、具备自主学习与自适应决策能力的新型控制方法，成为机器人控制领域的研究重点与发展趋势。

强化学习是人工智能领域实现自主智能决策的核心技术，核心逻辑是模拟生物的试错学习机制，让智能体在未知环境中通过持续交互获取经验，进而优化自身行为策略。不同于依赖标注数据的监督学习、仅挖掘数据分布的无监督学习，强化学习以长期收益最大化为目标，属于典型的序贯决策学习范式，无需先验知识与人工干预即可完成策略迭代，是连接感知与控制、实现机器自主化的关键纽带。

1.4 国内外研究现状

在国际研究层面，国外学者围绕强化学习与机器人控制的融合开展了前沿探索，研究起步早、体系相对完善。麻省理工学院、斯坦福大学、谷歌 DeepMind 等顶尖机构，依托深度强化学习算法，在机械臂柔性操控、足式机器人运动规划、多智能体协同等领域实现突破，研发出 DDPG、PPO、SAC 等经典算法并完成真机落地验证，部分成果已应用于工业分拣、航天探测等场景，侧重算法创新与高端硬件适配，研究偏向高复杂度、高精度任务的决策优化。




图 1 DDPG 算法框架

国内研究虽起步稍晚，但近年来发展迅猛，紧跟国际前沿并贴合本土产业需求。清华大学、哈尔滨工业大学、中国科学院等高校院所，聚焦工业机械臂、移动机器人、特种机器人等国产装备，针对强化学习样本效率低、虚实迁移难、鲁棒性不足等痛点开展本土化改进，在动态避障、多机协同、自适应控制等方向取得大量理论与实验成果，逐步实现从仿真验证到工程落地的过渡。但整体而言，国内研究在高端算法原创性、极端环境适配性、大规模产业化应用方面仍与国际顶尖水平存在一定差距，核心技术瓶颈有待进一步突破。

综合来看，当前国内外研究均聚焦深度强化学习与机器人控制的深度融合，核心围绕算法优化、场景适配、虚实迁移展开，但在非结构化极端环境适应性、小样本高效学习、多机协同稳定性等方面仍存在诸多难题，这也为本文的研究提供了切入点与创新方向^[2]。

1.5 强化学习在机器人控制中的应用

随着深度学习与强化学习的深度融合，深度强化学习进一步突破了传统强化学习的状态表征瓶颈，借助神经网络实现高维状态空间的高效处理，大幅拓展了应用边界。强化学习技术体系不断完善，在机器人控制领域的应用愈发成熟多元，核心落地场景涵盖以下几类：

1.5.1 机器人运动规划与轨迹优化

该应用主要解决机器人在静态、动态复杂非结构化环境中的实时路径寻优与轨迹平滑问题，是机器人实现自主移动的基础核心。传统运动规划方法多依赖全局预设地图、人工标定路径点，采用 A*、RRT 等经典算法，仅能应对静态规整环境，面对动态

障碍物突袭、地形突变、空间狭窄等场景时，响应滞后、轨迹僵硬，极易出现碰撞卡顿或路径冗余问题，自适应能力与实时性难以满足复杂作业需求。

基于强化学习的运动规划方法，将机器人视作智能体，以环境感知数据为状态输入，以关节转速、移动方向、步长为动作空间，结合避障惩罚、路径最短、能耗最低等指标设计奖励函数，驱动机器人通过海量试错交互自主学习决策规则。依托强化学习算法对高维环境信息的处理能力，机器人可实时感知周边动态变化，在线修正行进轨迹，既能灵活规避动态障碍物与崎岖地形，又能优化运动姿态、缩短行程耗时、降低机械能耗，广泛适用于轮式移动机器人、足式仿生机器人等的自主行走、动态避障、窄空间通行等场景，大幅提升机器人在未知环境中的移动自主性与作业安全性^[5]。




图 2 强化学习飞行控制仿真系统的整体架构

1.5.2 机械臂精准操作与柔性操控

机械臂精细化柔性操控是智能制造、物流仓储、家政服务、医疗辅助等领域的核心技术痛点，涵盖目标抓取、精密装配、曲面打磨、物料分拣、柔性插接等多项高精度作业任务，对机器人的力位协同控制、环境感知适配、操作稳定性提出了严苛要求^[6]。传统机械臂控制多采用示教再现、预设轨迹+PID 闭环控制模式，不仅需要人工反复示教调参、通用性极差，而且缺乏力感知与柔性调节能力，面对易碎品、软质材料、不规则异形工件时，极易出现夹持破损、定位偏差、装配卡死等问题，难以应对非结构化、小批量、多品类的柔性生产需求。

基于强化学习的机械臂控制方法，将机械臂本体作为决策智能体，以视觉感知、力觉反馈、关节位姿等多源信息作为状态输入，以关节转角、夹持力度、运动速度、末端执行器姿态作为动作空间，结合任务目标设计分层奖励函数，将抓取成功率、力控误差、装配精度、无碰撞作业等指标量化为奖惩信号，驱动智能体通过海量仿真与真机交互试错，自主迭代优化操控策略。结合深度确定性策略梯度（DDPG）^[7]、近

端策略优化（PPO）等经典深度强化学习算法，可有效处理高维感知数据、实现连续动作空间的精准决策^[8]，让机械臂自主习得柔性接触力控、精准定位、自适应夹持等技能，无需依赖精准的刚体动力学模型，即可完成玻璃制品、生鲜食材等易碎软质物件的稳定抓取，精密齿轮、电子元器件的高精度装配，以及曲面工件的自适应打磨，大幅提升机械臂的作业通用性、柔性度与精度，推动工业机器人从标准化批量作业向智能化柔性制造转型。

1.5.3 多机器人协同控制

多机器人协同控制是智能制造、智慧仓储、应急救援、电力巡检、航天探测等领域的关键技术需求，旨在通过多机协作完成单机器人无法胜任的大负载搬运、大范围巡检、分布式探测等复杂任务，核心难点在于群体决策协同、路径冲突规避、任务动态分配与系统鲁棒性保障。传统多机协同多采用集中式控制架构，依托中央主控节点统一下发指令、规划路径，不仅存在通信延迟高、单点故障易致系统瘫痪的弊端，而且面对动态任务变更、环境扰动时响应迟缓，难以实现灵活的分布式协作。

基于强化学习的多机器人协同控制，采用分布式智能体架构，将每台机器人视为独立决策单元，以自身位姿、传感器感知、同伴状态、全局任务进度作为联合状态输入，以移动路径、作业动作、通信交互作为动作空间，兼顾局部任务收益与全局协同目标设计分层奖励函数，将无冲突行进、任务完成度、能耗均衡、编队稳定性等指标量化为奖惩信号。借助多智能体强化学习算法，各机器人可通过局部交互与全局奖励反馈，自主学习协同策略，实现动态编队、任务按需分配、路径冲突消解、故障自适应替补。相较于传统集中式控制，该方法具备极强的鲁棒性、扩展性与环境适应性，无需人工干预即可应对场景突变、单体故障等突发状况，适用于仓储集群搬运、电网多机巡检、灾区协同救援、水下分布式探测等场景，大幅提升群体机器人系统的作业效率与任务成功率。

1.5.4 机器人自主导航与姿态控制

机器人自主导航与姿态控制是移动类机器人实现全域自主作业的核心支撑，导航负责实现机器人从起点到终点的无碰撞路径规划与定位，姿态控制则保障机器人在复杂地形、外力扰动、高速移动工况下的机身稳定性，二者协同决定机器人的环境适应能力与作业可靠性。传统自主导航多依赖 GPS、激光雷达、预设栅格地图，采用 SLAM 算法配合人工设定路径实现定位导航，不仅在信号屏蔽、无特征环境中定位失效，且姿态控制多采用固定参数 PID 调节，面对地形起伏、风力干扰、水流冲击等突发扰动时，姿态调节滞后、鲁棒性差，极易出现打滑、倾覆、偏移航线等问题，难以适配野外、井下、水下、室内杂乱环境等非结构化场景。

基于强化学习的自主导航与姿态控制，将机器人本体作为闭环决策智能体，以激光雷达、视觉、惯性测量单元（IMU）、GPS 等多源传感器融合数据为状态输入，以移动速度、转向角度、机身倾角、旋翼转速/履带扭矩等为连续动作空间，结合导航

目标设计复合奖励函数，将定位精度、航线偏差、姿态平稳度、无碰撞通行、能耗控制等指标量化为奖惩信号，驱动智能体通过海量环境交互试错，自主学习导航决策与姿态调节策略^[9]。结合深度强化学习算法，可实现高维感知信息的实时处理与连续动作的精准输出，让机器人在未知环境中自主完成实时定位、增量式建图、动态路径修正，同时根据地形起伏、外力扰动、负载变化快速微调机身姿态，抑制晃动、防止倾覆、锁定航线^[10]。该方法摆脱了对高精度地图、固定导航设备的强依赖，具备极强的自适应调节能力与抗干扰能力，可广泛应用于野外勘探、井下巡检、水下探测、室内家政、灾害搜救等复杂场景，大幅提升移动机器人的自主作业范围与运行稳定性。

参 考 文 献

- [1] 殷波, et al. “基于模糊逻辑的多机器人系统智能学习方法.” 中南大学学报(自然科学版): 2005 年中国智能自动化会议(ICAC’ 2005), 青岛, 2005. n.d., pp. 142-146.
- [2] 陶显, 侯伟, 徐德. 基于深度学习的表面缺陷检测方法综述[J]. 自动化学报, 2021, 47(5):1017-1034. DOI:10.16383/j.aas.c190811.
- [3] Sutton R S, Barto A G. Reinforcement Learning: An Introduction [M]. 2nd ed. Cambridge, MA: MIT Press, 2018.
- [4] Puterman M L. Markov Decision Processes: Discrete Stochastic Dynamic Programming [M]. Hoboken, NJ: John Wiley & Sons, 2014.
- [5] 陈尧伟, 吕明, 张捷. 基于深度强化学习与非线性模型预测方法的四足机器人运动控制[J]. 兵工学报, 2026, 47(1):307-317. DOI:10.12382/bgxb.2025.0565.
- [6] 刘城焱, 胡健, 姚建勇, 等. 强化学习驱动下的柔性机械臂双时间尺度组合控制[J]. 控制理论与应用, 2025, 42(3):541-552. DOI:10.7641/CTA.2023.30349.
- [7] Liu Y C, Huang C Y. DDPG-based adaptive robust tracking control for aerial manipulators with decoupling approach[J]. IEEE Transactions on Cybernetics, 2021, 52(8): 8258-8271.
- [8] Wei D, Zhang L, Liu Q, et al. UAV swarm cooperative dynamic target search: a MAPPO-based discrete optimal control method[J]. Drones, 2024, 8(6): 214.
- [9] 赵军, 何家政, 孙冰寒, 等. 基于深度强化学习的四旋翼无人机姿态控制[J]. 中国惯性技术学报, 2025, 33(3):284-292, 300. DOI:10.13695/j.cnki.12-1222/o3.2025.03.010.
- [10] Koch W, Mancuso R, West R, et al. Reinforcement learning for UAV attitude control[J]. ACM Transactions on Cyber-Physical Systems, 2019, 3(2): 1-21.